

Sztuczna Inteligencja

Modelowanie silnych przekonań

Alicja Kowalewska 165726

Alicja Smaruj 165151

Maciej Retowski 165429

maj 2018

1 Cele projektu

Celami projektu były ocena, na ile podstawowe metody przetwarzania tekstów pozwalają modelować zawarte w nich silne przekonania, oraz sprawdzenie, czy zastosowane modelowanie będzie wystarczające do stworzenia programu umożliwiającego klasyfikację artykułów zgodnie z wyrażanym w nich poglądem.

Programy rozpoznające przekonania w tekście pisanym w języku naturalnym mogą mieć bardzo wiele zastosowań, na przykład rozróżnianie pozytywnych i negatywnych komentarzy czy łatwe wyszukiwanie artykułów zawierających określone stanowisko.

2 Opis projektu

Przekonania, których modelowanie spróbowano przeprowadzić, dotyczyły katastrofy smoleńskiej. Część artykułów dostępnych w internecie odzwierciedla pogląd, iż rzeczywiście była to katastrofa, podczas gdy w innych zdarzenie to jest traktowane jako zamach.

Podjęta została próba przeanalizowania podobieństw i różnic pomiędzy artykułami wyrażającymi te dwa przekonania. Oczekiwany rezultat było pokazanie, że podstawowe metody przetwarzania tekstu umożliwiają dostrzeżenie (i określenie) różnicy pomiędzy artykułami wyrażającymi przeciwne poglądy.

Skrypty stworzone podczas pracy nad projektem, o których mowa w dalszej części sprawozdania, oraz pełne wyniki znajdują się pod adresem: <https://github.com/mreto/SI>.

3 Zastosowane metody

3.1 Zgromadzenie danych

Stworzyliśmy trzy zbiory artykułów:

- wyrażające przekonanie o katastrofie,
- wyrażające przekonanie o zamachu,
- neutralne

oraz

- zbiór słów kluczowych.

Do stworzenia pierwszych dwóch katalogów zostały wykorzystane materiały wcześniej zgromadzone, zaklasyfikowane i przygotowane przez inną grupę projektową. Zawierały one artykuły o wydarzeniu z 10 kwietnia 2010 roku opublikowane w latach 2010 - 2016: 29 o katastrofie i 41 o zamachu.

Oprócz tego użyto zbioru 60 słów kluczowych – najważniejszych słów związanych z tematem artykułów (te również wybrane zostały przez grupę pracującą nad podobnym zagadnieniem w ubiegłych latach).

154	kabina	pancerny	Smolensk
analiza	Kaczynski	pilot	spis
Antoni	katastrofa	pogoda	stenogram
blad	klamstwo	prezydent	strzał
Blasik	komisja	prokuratura	swiadek
bomba	Komorowski	przyczyny	trotyl
Bronisław	Krauze	Putin	tupolew
brzoza	krzyk	Rosja	Tusk
Donald	krzyż	rosyjski	wieża
dym	lotnisko	samolot	wrak
ekspert	Macierewicz	sekcja	wybuch
film	mgła	skrzydło	zamach
general	nacisk	skrzynka	zaniedbanie
hanba	nalega	śląd	zbrodnia
identyfikacja	ofiary	sledztwo	zdrada

Rysunek 1: Lista słów kluczowych.

W celu zebrania neutralnych danych zastosowano skrypt `pars_wiki.py`¹ pobierający artykuły z Wikipedii zawierające wybrane słowa kluczowe i w ten sposób otrzymano zbiór 46 neutralnych artykułów. Poddano je wstępnemu przetworzeniu ułatwiającemu dalszą pracę – pozbyto się polskich znaków, wielkich liter oraz znaków nowej linii.

3.2 Przetwarzanie tekstów

Każdą z grup artykułów przetworzono do postaci macierzy za pomocą skryptu `script.py`² w następujący sposób:

- każdemu słowu kluczowemu odpowiada wiersz w macierzy – wektor słów kontekstowych
- dla każdego wystąpienia wybranego słowa kluczowego w tekście znaleźć należy słowa występujące w pobliżu – określany jest margines (przyjęto granicę równą 5), ile słów następujących po słowie kluczowym i ile słów poprzedzających je, będzie brane pod uwagę
- jeśli w granicy tego marginesu pojawiają się znaki sygnalizujące koniec zdania (. ! ?), słowa nienależące do tego samego zdania zostają odrzucone
- im bliżej słowo jest położone od słowa kluczowego, tym większą otrzymuje wagę (... , 0, 1, 2, 3, 4, 5, SłowoKluczowe, 5, 4, 3, 2, 1, 0, 0 ...)
- przy pomocy odpowiedniego słownika³ przeprowadzona zostaje lematyzacja słowa (czyli wyznaczony odpowiadający danej formie gramatycznej leksem)

¹https://github.com/mreto/SI/blob/master/pars_wiki.py

²<https://github.com/mreto/SI/blob/master/script.py>

³Słownik, z którego skorzystano, został stworzony na podstawie słownika fleksyjnego Polimorf dostępnego w ramach programu Morfeusz (<http://sgjp.pl/morfeusz/index.html>).

- jeśli słowo kontekstowe nie wystąpiło wcześniej, zostaje dodane jako nowa kolumna macierzy i w komórce odpowiadającej słowu kluczowemu ustawiona zostaje odpowiednia waga, jeśli wystąpiło ono już wcześniej, waga odpowiedniej komórki zostaje zwiększona

Po przetworzeniu wszystkich artykułów i stworzeniu macierzy przeanalizowano otrzymane rezultaty. Zredukowano liczbę kolumn o ok. 70%, odcinając słowa powtarzające się zbyt rzadko (mające sumaryczną wagę mniejszą niż 10 i takie, które ponad połowę swoich wystąpień uzyskały przy tym samym słowie kluczowym). Następnie gotowe wektory poddano normalizacji, aby umożliwić ich późniejsze porównywanie. W tym celu dla każdego wektora szukano maksimum i dzielono przez jego wartość wszystkie pozostałe wartości.

Poniżej przedstawionych zostało kilka przykładowych słów kluczowych wraz z ich słowami kontekstowymi, które uzyskały największe wartości wag (podane wagi przed normalizacją):

TUPOLEW		SPISEK		PRZYCZYNY	
Słowa kontekstowe	Waga	Słowa kontekstowe	Waga	Słowa kontekstowe	Waga
z	32	teoria	20	katastrofa	176
na	23	z	7	i	46
skrzydło	20	sie	7	z	41
miec	19	i	6	okolicznosc	36
wrak	19	byc	5	do	31
który	18	przekonywac	5	sie	30
prezydencki	15	nowy	4	badanie	28
rozbic	15	wiecej	4	wypadek	23
i	14	zamach	4	prawdopodobny	20
byc	13	kolejny	4	jako	20

Tabela 1: Wektory kontekstowe na podstawie artykułów zawierających przekonanie o zamachu

TUPOLEW		SPISEK		PRZYCZYNY	
Słowa kontekstowe	Waga	Słowa kontekstowe	Waga	Słowa kontekstowe	Waga
w	56	w	12	katastrofa	100
prezydencki	45	i	12	smolenski	36
na	22	zamach	12	z	23
z	19	on	10	badajacy	20
sie	14	o	7	sie	18
który	14	wielki	5	komisja	16
wrak	10	lubic	5	do	15
skrzydło	10	portal	5	i	13
katastrofa	9	byc	5	on	13
o	9	to	5	w	12

Tabela 2: Wektory kontekstowe na podstawie artykułów zawierających przekonanie o katastrofie

Obszerniejsza analiza wszystkich słów kluczowych znajduje się pod adresem: https://github.com/mreto/SI/tree/master/analize_vectors

3.3 Mapy samoorganizujące

W celu umożliwienia interpretacji otrzymanych wektorów zastosowano tzw. mapy samoorganizujące się (inaczej mapy Kohonena lub SOM – Self Organizing Maps).

Sieć Kohonena, na której bazują SOM-y, jest to sieć neuronowa uczona w trybie bez nauczyciela w celu sklasyfikowania wielowymiarowych danych wejściowych w taki sposób, aby umożliwić ich reprezentację w mniejszej liczbie wymiarów, a jednocześnie jak najwierniej odwzorować wewnętrzną strukturę wektora wejściowego.

Do generowania map użyto gotowych funkcji z pakietu SomToolBox dla GNU Octave⁴. Początkowo zastosowano domyślne parametry i rozmiar mapy 12 x 12. W ramach testów sprawdzono

⁴<https://github.com/limosek/somtoolbox>

skuteczność także dla innych parametrów: metody początkowej inicjalizacji 'randint', dla map o większym rozmiarze (30 x 30) oraz dla algorytmu treningu 'seq'.

3.4 Metody analizy wyników

Aby umożliwić ocenę zgodności działania map samoorganizujących się z oczekiwaniami, wygenerowano mapy:

- dla zbioru artykułów zgodnych z przekonaniem o katastrofie,
- dla zbioru artykułów zgodnych z przekonaniem o zamachu,
- dla zbioru artykułów neutralnych,
- dla 29 stadiów pośrednich pomiędzy artykułami stronnictwymi i neutralnymi uzyskanych poprzez dodawanie stopniowo do zbioru artykułów neutralnych coraz większych porcji artykułów stronnictwowych,
- dla 29 stadiów pośrednich pomiędzy artykułami stronnictwowymi i neutralnymi uzyskanych poprzez dodawanie do zbioru artykułów neutralnych kolejnych wielokrotności zbioru artykułów stronnictwowych, tak aby zmienić proporcje liczności zbioru artykułów stronnictwowych względem neutralnych.

Następnie stworzono macierze zawierające odległości pomiędzy wszystkimi parami słów kluczowych znajdującymi się na SOM-ach (czyli liczbową reprezentację wyników uzyskanych dzięki SOM-om) oraz obliczono podobieństwa między macierzami generowanymi w poszczególnych krokach a macierzami danych neutralnych i stronnictwowych według wzoru:

$$\text{podobienstwo} = \sum_{i=1}^n \sum_{j=1}^n |a_{i,j} - b_{i,j}|$$

gdzie:


- n to ilość słów kluczowych,
- a to element macierzy odległości pomiędzy parami słów kluczowych na mapie przedstawiającej badany pogląd,
- b to element macierzy odległości pomiędzy parami słów kluczowych na mapie przedstawiającej pogląd neutralny lub stronnictwowy.

Wyliczenie powyższych wartości umożliwia dość łatwe porównywanie podobieństw między mapami. Na tej podstawie spróbowano stworzyć prosty klasyfikator rozpoznający, do którego poglądu badany artykuł jest bardziej podobny.

4 Wyniki


4.1 Mapy samoorganizujące się

Poniżej znajdują się mapy wygenerowane przy domyślnych ustawieniach kolejno dla danych: neutralnych, wyrażających przekonanie o katastrofie oraz wyrażających przekonanie o zamachu.




SOM 16-May-2018

Rysunek 2: SOM dla danych neutralnych.



SOM 17-May-2018

Rysunek 3: SOM dla danych wyrażających przekonanie o katastrofie.



SOM 17-May-2018

Rysunek 4: SOM dla danych wyrażających przekonanie o zamachu.

Na przedstawionych powyżej mapach można zaobserwować wykryte powiązania pomiędzy słowami kluczowymi, np. blisko siebie leżą takie pary jak: "Bronisław" + "Komorowski", "mgła" + "pogoda", "brzoza" + "skrzydło", "trotyl" + "bomba", "identyfikacja" + "sekcja", "rosja" + "Putin".

4.2 Przejścia pomiędzy mapą neutralną a stroniczą

4.2.1 Komentarz do wykresów


Widoczne poniżej rys. 5, 6, 7 i 8 przedstawiają wykresy pozwalające ocenić podobieństwa między mapami neutralnymi i związanymi z jakimś poglądem a wersjami pośrednimi.

Na rys. 5 widać, że gdy dodawano do mapy neutralnej kolejne porcje artykułów wyrażających pogląd o katastrofie, różnica względem mapy neutralnej wzrastała (zwłaszcza w początkowych dziesięciu iteracjach), a różnica względem mapy wyrażającej pogląd o katastrofie malała i pozostawała w większości przypadków niższa niż względem mapy wyrażającej pogląd o zamachu. Sytuacja jest analogiczna w przypadku rys. 6 (prezentującym zmiany podczas dodawania kolejnych porcji artykułów wyrażających pogląd o zamachu) – z tą różnicą, że krzywe katastrofy i zamachu są bliższe względem siebie i wielokrotnie się przecinają.

Na rys. 7 i 8 można zaobserwować, że przy wielokrotnym dodaniu zestawu artykułów związanych z danym poglądem do mapy neutralnej wynik staje się coraz bliższy temu pogładowi – czerwona krzywa na rys. 7 i żółta krzywa na rys. 8 mają tendencje malejące. Dodatkowo widać, że proces ten oddala mapę od neutralnej, ale jej różnica względem poglądu przeciwnego nie ulega znacznym zmianom.


4.2.2 Wykresy

Wyniki przy dodawaniu porcji artykułów wyrażających pogląd o katastrofie




Rysunek 5: Wykres obrazujący zmiany map podczas dodawania kolejnych artykułów wyrażających przekonanie o katastrofie.

Wyniki przy dodawaniu porcji artykułów wyrażających pogląd o zamachu




Rysunek 6: Wykres obrazujący zmiany map podczas dodawania kolejnych artykułów wyrażających przekonanie o zamachu.

Wyniki przy dodawaniu powielonych artykułów wyrażających pogląd o katastrofie



Rysunek 7: Wykres obrazujący zmiany map podczas dodawania kolejnych wielokrotności zbioru artykułów wyrażających przekonanie o katastrofie.

Wyniki przy dodawaniu powielonych artykułów wyrażających pogląd o zamachu



Rysunek 8: Wykres obrazujący zmiany map podczas dodawania kolejnych wielokrotności zbioru artykułów wyrażających przekonanie o zamachu.

4.3 Wykresy obrazujące klasyfikację artykułów

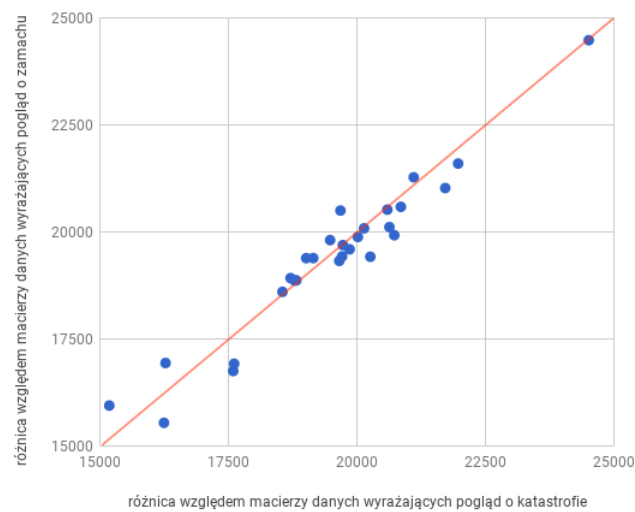
4.3.1 Komentarz do wykresów

Dzięki rys. 9 i 10 można ocenić, czy mapy dla artykułów z poszczególnych grup rzeczywiście okazują się bliższe mapie dla wyrażanego w nich poglądu.

Na rys. 9 i 10 widać, że zarówno artykuły wyrażające pogląd o katastrofie, jak i wyrażające pogląd o zamachu układają się bardzo blisko przekątnej wykresu, co oznacza, że zachowują podobne odległości od obu poglądów. Na rys. 11 i 12 tendencja jest bliższa oczekiwaniom. Na rys. 11 większość punktów (choć nadal niewiele więcej niż połowa) znajduje się nieco powyżej przekątnej, co oznacza ich większą bliskość względem mapy wyrażającej pogląd o katastrofie niż do tej wyrażającej pogląd o zamachu. Analogicznie na rys. 12 – większość punktów (tym razem jednak zdecydowana większość) znajduje się nieco poniżej przekątnej, co sygnalizuje, że artykuły bliższe są poglądowi o zamachu.

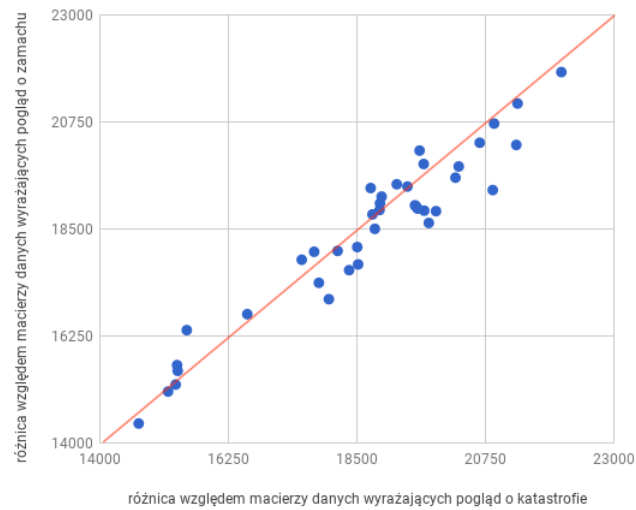
4.3.2 Wykresy

Położenie artykułów wyrażających pogląd o katastrofie
względem macierzy związanych z katastrofą
i zamachem



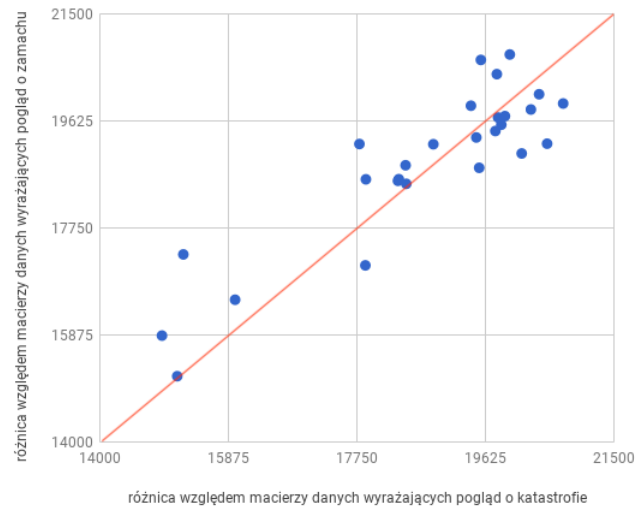
Rysunek 9: Wykres odległości pojedynczych artykułów związanych z poglądem o katastrofie względem map w pełni stronicznych.

Położenie artykułów wyrażających pogląd o zamachu
względem macierzy związanych z katastrofą
i zamachem




Rysunek 10: Wykres odległości pojedynczych artykułów związanych z poglądem o zamachu względem map w pełni stronicznych.

Położenie artykułów wyrażających pogląd o katastrofie
względem macierzy związanych z katastrofą
i zamachem przy zastosowaniu parametru 'seq'



Rysunek 11: Wykres odległości pojedynczych artykułów związanych z poglądem o katastrofie względem map w pełni stronicznych przy zastosowaniu parametru 'seq' podczas tworzenia SOM-ów.



Rysunek 12: Wykres odległości pojedynczych artykułów związanych z poglądem o zamachu względem map w pełni stronicznych przy zastosowaniu parametru 'seq' podczas tworzenia SOM-ów.

4.4 Klasyfikator

Prosty klasyfikator porównujący mapę każdego artykułu z mapą wyrażającą przekonanie o katastrofie i mapą wyrażającą przekonanie o zamachu osiągnął następujące wyniki:

1. przy domyślnych ustawieniach - skuteczność 53,2% (rozpoznał 62,5% artykułów wyrażających przekonanie o zamachu i 40% artykułów wyrażających przekonanie o katastrofie),
2. dla map o rozmiarze 30x30 - skuteczność 53,5% (rozpoznał 70% artykułów wyrażających przekonanie o zamachu i 30% artykułów wyrażających przekonanie o katastrofie),
3. dla inicjalizacji 'randinit' - skuteczność 45,6% (rozpoznał 25% artykułów wyrażających przekonanie o zamachu i 75% artykułów wyrażających przekonanie o katastrofie),
4. dla algorytmu treningu 'seq' - skuteczność 74,9% (rozpoznał 87,5% artykułów wyrażających przekonanie o zamachu i 57% artykułów wyrażających przekonanie o katastrofie),
5. dla algorytmu treningu 'seq' i metody obliczania sąsiedztwa 'gaussian' - skuteczność 70,6% (rozpoznał 67,5% artykułów wyrażających przekonanie o zamachu i 75% artykułów wyrażających przekonanie o katastrofie).

5 Wnioski

Z zaprezentowanych powyżej wykresów (rys. 5 - 8) można wywnioskować, iż przygotowane mapy Kohonena w pewnym stopniu odzwierciedlają przekonanie zawarte w zbiorze tekstów. Dodawanie stronicznych artykułów do początkowo neutralnego zbioru rzeczywiście powoduje odchylenie wartości w odpowiednich kierunkach.

W przypadku zastosowania algorytmu treningu 'batch' mapy dla tekstów branych osobno nie wykazują zbyt dużego podobieństwa do żadnej z grup. Różnice pojedynczych artykułów względem przekonania o katastrofie a względem przekonania o zamachu (rys. 9 i 10) nie są wystarczająco duże, aby można było na ich podstawie stworzyć klasyfikator. Prawdopodobnie jest to związane

z faktem, iż testowane artykuły są zbyt krótkie, aby na bazie pojedynczego tekstu mapa była w stanie wiarygodnie zobrazować zawarte w nim zależności. Jeden artykuł nie zawiera większości słów kluczowych, a średnia długość wektorów kontekstowych wynosi ok. 17 słów (podczas gdy dla pełnych zbiorów było to ok. 500). Wyjaśniałoby to niezbyt dobrą skuteczność klasyfikatora w przypadkach 1-3.

Wykorzystanie sekwencyjnego algorytmu uczenia pozwoliło osiągnąć znacznie lepsze rezultaty. Jest to spowodowane tym, że sekwencyjny algorytm lepiej nadaje się w przypadku niewielkich zbiorów danych zawierających dużą liczbę zer.

Dodatkową poprawę rezultatów mogłoby spowodować:

- usunięcie z wektorów kontekstowych spójników oraz innych nieistotnych słów,
- wychwytywanie zaprzeczeń w tekstach,
- zwiększenie liczby badanych artykułów,
- dobór innego zestawu słów kluczowych.